📖 Nota Metodológica: Arquitetura do Cockpit de Risco Setorial

Modelo de Risco Setorial Interativo · versão 6.2 · código e dados: github.com/fernandoxb/sector-risk-model

Esta nota descreve as bases teóricas, as métricas de cauda e a estrutura de grafos do cockpit de risco. O objetivo é monitorizar o risco sistémico e o contágio entre os 11 setores do mercado (GICS) e as respetivas ações.

Para correr o cockpit: `.venv/bin/streamlit run app/cockpit/app.py` (a partir da raiz do projeto). Código de cálculo: `src/models/cockpit.py`.

📐 1. Métricas de risco de cauda

O modelo não assume que os retornos seguem uma distribuição normal. Concentra-se nos **eventos extremos (tail risk)** através de duas métricas principais.

A. Conditional Value at Risk (CVaR / Expected Shortfall)

O VaR diz apenas a partir de que perda começam os piores (1−α) dias. O CVaR calcula a **perda média dentro desses dias**: com α = 0,95, é a média dos 5% piores retornos diários. É histórico e usa retornos simples na janela escolhida.

$$\mathrm{VaR}_\alpha = -Q_{1-\alpha}(r), \qquad \mathrm{CVaR}_\alpha = \mathrm{ES}_\alpha = -\,\mathbb{E}\left[\, r \mid r \le Q_{1-\alpha}(r) \,\right]$$

em que $Q_{1-\alpha}$ é o quantil empírico dos retornos simples diários da janela, e as perdas vêm em número positivo.

Padrão do projeto: α = 0,975 (o nível do Expected Shortfall no FRTB, Basileia III) e janela de 3 anos, definidos em `config/settings.py` (`CVAR_LEVEL`, `CVAR_YEARS`). Todos os separadores do cockpit e os relatórios usam a mesma função (`src/models/cockpit.py::cvar`), por isso dão o mesmo número com os mesmos parâmetros.

- **Aplicação visual:** o tamanho de cada nó do grafo é proporcional ao CVaR, já ajustado ao regime de juros (ver secção 4).

B. Downside Beta (beta condicional de crise)

$$\beta^{-} = \frac{\mathrm{cov}(r_i, r_{SPY} \mid r_{SPY} \le q_p)}{\mathrm{var}(r_{SPY} \mid r_{SPY} \le q_p)}$$

Usa apenas os dias em que o SPY ficou no percentil de pânico p, que é ajustável no painel. Mostra que setores e ações amplificam as perdas em correções sistémicas.

🕸️ 2. Topologia de rede e filtragem de ruído (MST)

Entre 11 setores há 55 correlações possíveis, o que torna o grafo completo ilegível. Para isolar a estrutura de contágio:

1. **Distância de correlação:** $d = \sqrt{2(1 - r)}$. Com $r = 1$, a distância é 0.
2. **Minimum Spanning Tree:** liga os 11 nós com 10 arestas, escolhidas de forma a minimizar a soma das distâncias.
3. **Posições no gráfico:** usa-se o layout de Kamada-Kawai, que trata d como uma distância. Assim, os setores que caem juntos ficam fisicamente próximos.

🔬 3. Duas camadas (setor → ativo)

- **Camada macro:** os 11 ETFs SPDR (XLK, XLF, XLE, …).
- **Camada micro:** as 10 maiores posições de cada ETF, no separador Teia de risco (secções 11 e 19). O CVaR de cada empresa é comparado com o CVaR do ETF do setor **no mesmo período**, e as ligações entre empresas vêm da MST das suas correlações. O antigo "microscópio" de 4 ações por setor foi substituído por este nível.

🏦 4. Regime de juros (Treasury 10Y via FRED)

- Série `DGS10`, lida pela `fredapi` quando `FRED_API_KEY` está definida e, caso contrário, pelo CSV público do FRED.
- **Regime:** variação do 10Y nos últimos 63 dias úteis. É *subida* se ≥ +0,25 p.p., *descida* se ≤ –0,25 p.p. e *estável* nos restantes casos.
- **Choque de juros (Análise ao vivo):** o utilizador escolhe uma variação Δy do 10Y e o CVaR de cada setor recebe por cima a perda estimada pelo seu β medido (secção 9, regressão semanal com erros HAC):

$$\mathrm{CVaR}_i^{choque} = \mathrm{CVaR}_i + \max\left(0,\ -\left(e^{\,b_i \Delta y} - 1\right)\right)$$

  Só contam as ligações significativas ($|t| \geq 2$); os outros setores não mudam, e um setor que ganha com o choque fica com o CVaR original.
- **Correção de uma incoerência (2026-11):** a versão anterior penalizava uma lista fixa de "setores de crescimento" (XLK, XLC, XLY) com um parâmetro arbitrário, o que contradizia a regressão do próprio projeto. Os dados dizem que quem sofre com a subida dos juros são o XLRE (t = –4,1), o XLU (–2,7) e o XLP (–2,4); o XLK não tem ligação significativa (t = +0,6) e o XLE até ganha (+2,8). A lista fixa e o parâmetro foram retirados.

📦 5. Persistência em Markdown (Obsidian)

O botão **Exportar estado de hoje** grava `<cofre>/Risco Setorial/AAAA-MM-DD.md` com:

- frontmatter com os parâmetros e o regime de juros, para consultas Dataview;
- a tabela de setores e a lista de ligações da MST, com todos os tickers como `[[Ticker]]` para gerar backlinks.

O cofre usado por omissão é `Documents/Obsidian Vault`, na subpasta `Risco Setorial/`, onde a nota `00 Painel.md` lista todos os logs com o Dataview. Pode ser alterado no painel ou com a variável `OBSIDIAN_VAULT`.

🧪 6. Backtesting do VaR e do Expected Shortfall (Sprint 2)

Código: `src/models/backtest.py` (funções puras) · parâmetros: `config/settings.py` (`BT_*`) · testes: `tests/test_backtest.py`. Saídas: `data/features/var_backtest.csv` (resultados) e `data/features/var_backtest_series.parquet` (séries diárias para o cockpit).

A. Previsão do VaR sem look-ahead

O VaR e o ES a 1 dia do dia t são previstos **só com dados até** $t-1$, em janela móvel de W = `CVAR_YEARS` × 252 = 756 dias úteis, para os níveis $\alpha \in \{99\%, 97{,}5\%\}$. Os três métodos usam retornos simples e dão o VaR e o ES em perda positiva:

- **Histórico:** $\mathrm{VaR}_t = -Q_{1-\alpha}(r_{t-W}, \ldots, r_{t-1})$, o quantil empírico (interpolação linear, igual a `risk_metrics.hist_var`). O ES é `cockpit.cvar` na mesma janela: a média das perdas a partir do VaR.
- **GJR-GARCH(1,1)-t:** estimado em retornos logarítmicos $x_t = \ln(1 + r_t)$ (em %), com média constante:

$$x_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim t_\nu \text{ padronizada}$$

$$\sigma_t^2 = \omega + (\alpha_1 + \gamma\, 1_{\varepsilon_{t-1}<0})\, \varepsilon_{t-1}^2 + \beta\, \sigma_{t-1}^2$$

  Os parâmetros são re-estimados no **1.º dia útil de cada mês** (`BT_REFIT_FREQ`) com as W observações anteriores. Entre re-estimações, os parâmetros ficam fixos e σ_t é atualizada todos os dias pela recursão. O quantil logarítmico passa a retorno simples pela transformação exata (monótona) $r = e^x - 1$:

$$\mathrm{VaR}_t = -\left(e^{\mu + \sigma_t\, q_{1-\alpha}(\nu)} - 1\right)$$

  O ES é a média de $-(e^{\mu+\sigma_t z} - 1)$ na cauda $z \le q_{1-\alpha}(\nu)$ da t. Calcula-se pela regra do ponto médio, com `BT_ES_GRID` = 400 quantis igualmente espaçados em probabilidade dentro de $(0, 1-\alpha)$.
- **GARCH-FHS (Filtered Historical Simulation, Barone-Adesi et al., 1999):** usa o mesmo GARCH, com os mesmos μ e σ_t, mas troca a t pela distribuição empírica dos resíduos padronizados $\hat{z}_s = (x_s - \hat{\mu})/\hat{\sigma}_s$ da janela de estimação em vigor. $\mathrm{VaR}_t = -(e^{\mu+\sigma_t \hat{q}} - 1)$, em que $\hat{q}$ é o quantil empírico $1-\alpha$ dos $\hat{z}$, e o ES é a média de $-(e^{\mu+\sigma_t \hat{z}} - 1)$ sobre os $\hat{z} \le \hat{q}$. Assim, a volatilidade vem do GARCH e a forma da cauda vem dos dados.

Os três métodos são comparados na mesma amostra: os dias em que ambos têm previsão (a partir de 2008 nos setores com história desde 2005; XLRE e XLC começam mais tarde).

B. Exceções

$I_t = 1\{-r_t > \mathrm{VaR}_t\}$. Com T dias e $x = \sum I_t$ exceções, a taxa observada é $\hat{p} = x/T$ e a esperada é $p = 1 - \alpha$.

C. Teste de Kupiec (POF, cobertura incondicional)

H_0: $\hat{p} = p$.

$$LR_{pof} = -2\ln\left[(1-p)^{T-x}p^{x}\right] + 2\ln\left[(1-\hat{p})^{T-x}\hat{p}^{x}\right] \sim \chi^2(1)$$

D. Teste de independência de Christoffersen

Sendo n_{ij} o número de dias no estado i seguidos de um dia no estado j (0 = sem exceção, 1 = exceção), $\pi_0 = \frac{n_{01}}{n_{00}+n_{01}}$, $\pi_1 = \frac{n_{11}}{n_{10}+n_{11}}$ e $\pi = \frac{n_{01}+n_{11}}{n_{00}+n_{01}+n_{10}+n_{11}}$. H_0: $\pi_0 = \pi_1$ (uma exceção hoje não torna mais provável outra amanhã).

$$LR_{ind} = -2\ln\left[(1-\pi)^{n_{00}+n_{10}}\pi^{n_{01}+n_{11}}\right] + 2\ln[(1-\pi_0)^{n_{00}}\pi_0^{n_{01}}(1-\pi_1)^{n_{10}}\pi_1^{n_{11}}] \sim \chi^2(1)$$

E. Teste condicional combinado

$$LR_{cc} = LR_{pof} + LR_{ind} \sim \chi^2(2)$$

Rejeita-se H_0 quando o p-valor é inferior a `BT_SIGNIF` = 5%. Em todos os testes, $0 \cdot \ln 0 = 0$ (casos com zero exceções ou sem exceções consecutivas).

F. Semáforo de Basileia

Conta as exceções dos **últimos 250 dias**. As zonas vêm da binomial acumulada $F(x) = P(X \le x)$, com $X \sim \mathrm{Bin}(250, 1-\alpha)$: **verde** se $F(x) < 95\%$, **amarelo** se $95\% \le F(x) < 99{,}99\%$, **vermelho** se $F(x) \ge 99{,}99\%$. A 99% isto dá as zonas do Comité de Basileia (1996): verde 0–4, amarelo 5–9, vermelho 10+. A 97,5% usa-se o mesmo critério (verde 0–10, amarelo 11–16, vermelho 17+), o que é uma extensão do projeto e não uma regra regulamentar.

G. Backtest do ES: teste Z2 de Acerbi–Székely (2014)

Com $L_t = -r_t$ e $p = 1 - \alpha$:

$$Z_2 = 1 - \frac{1}{T\,p}\sum_{t=1}^{T}\frac{L_t\, I_t}{\mathrm{ES}_t}$$

Se o ES estiver bem previsto, $\mathbb{E}[L_t I_t] = p\,\mathrm{ES}_t$ e, portanto, $\mathbb{E}[Z_2] = 0$. $Z_2 < 0$ quer dizer que as perdas nos dias de exceção são maiores ou mais frequentes do que o modelo prevê, ou seja, o ES está subestimado. O Z2 testa o VaR e o ES ao mesmo tempo.

P-valor por simulação (unilateral, `BT_ES_NSIM` = 1000 cenários, semente `BT_SEED`): em cada cenário, a perda de cada dia é tirada da distribuição que o próprio método previu para esse dia:

- histórico: reamostragem uniforme dos W retornos anteriores;
- GARCH-t: $\mu + \sigma_t z$, com z tirado da t padronizada;
- FHS: $\mu + \sigma_t \hat{z}$, com $\hat{z}$ reamostrado dos resíduos da estimação em vigor.

O Z_2 de cada cenário usa os VaR e ES previstos. Depois, $p = \frac{1+\#\{Z_2^{sim} \le Z_2^{obs}\}}{1+N}$, pelo que o menor p-valor possível é $1/1001 \approx 0{,}001$.

H. Backtest por mesa do FRTB

No FRTB (BCBS d457, §32.5), uma mesa de negociação perde a aprovação do modelo interno se, nos últimos 250 dias, tiver **mais de 12 exceções do VaR a 99%** ou **mais de 30 a 97,5%** (`BT_FRTB_MAX`). Aplica-se aqui a cada setor como se fosse uma mesa.

I. Validação

- O Kupiec e o Christoffersen são comparados com o cálculo feito à mão com `math.log`, e o p-valor com $\operatorname{erfc}(\sqrt{LR/2})$.
- O VaR histórico é comparado com `risk_metrics.hist_var` na janela $[t-W, t-1]$.
- O VaR GARCH (e a própria σ_t) é comparado com a recursão GJR escrita à mão a partir dos parâmetros estimados.
- O ES da t, calculado pela grelha, é comparado com a fórmula fechada $\mathbb{E}[T \mid T \le q] = -\frac{f_\nu(q)}{p}\,\frac{\nu+q^2}{\nu-1}$, reescalada para variância 1.
- Os resíduos da FHS são comparados com $(x-\hat{\mu})/\hat{\sigma}$ calculados à mão, e o VaR e o ES da FHS com o quantil e a média da cauda à mão.
- O Z2 é comparado com um exemplo calculado à mão. Com perdas normais e o VaR/ES normais verdadeiros, $\bar{Z}_2 \approx 0$; com o desvio-padrão real 1,5× maior do que o previsto, $Z_2 < -1$ e $p < 1\%$.
- A simulação histórica só usa retornos da janela $[t-W, t-1]$.
- **Sem look-ahead:** alterar o retorno do dia t e de todos os seguintes não muda nenhum VaR nem ES até ao dia t, nos três métodos (testado num dia de re-estimação e num dia a meio do mês).
- Reutilizar os parâmetros do mês anterior como ponto de partida do otimizador altera o VaR GARCH em no máximo 0,1% e não muda nenhuma exceção (verificado no XLK).

J. Leitura dos resultados (dados até 2026-11-09)

- **Histórico:** chumba a independência em 10 dos 11 setores. A janela de 3 anos reage devagar e as exceções aparecem em grupos nas crises.
- **GARCH-t:** reage à volatilidade e passa quase sempre a independência, mas tem exceções a mais (1,4–1,7% a 99%) e o Z2 rejeita o ES em todos os setores. A t simétrica com o v estimado tem a cauda esquerda demasiado leve.
- **GARCH-FHS:** junta o melhor dos dois. A volatilidade do GARCH resolve o agrupamento das exceções e a cauda empírica corrige a cobertura. O Kupiec e o Z2 só a rejeitam no XLE, o setor com a cauda mais instável (choques do petróleo). O teste condicional rejeita-a no XLE e, a 99%, também no XLI e no XLB (p = 0,048 e 0,039), por exceções agrupadas.
- Nenhum setor reprova o backtest por mesa do FRTB nos últimos 250 dias, com qualquer dos métodos.

L. A escolha do método resiste a dados que não entraram nela?

Escolher o método e avaliá-lo com os mesmos dados enviesa a conclusão (enviesamento de seleção). Para o medir, as previsões são divididas em `BT_SPLIT` = 2019-01-01. As previsões são as mesmas do backtest; só muda a amostra em que os testes são feitos. Um setor só conta num período com pelo menos 500 previsões.

Número de setores que passam os **três** testes (Kupiec, Christoffersen e Z2), dados até 2026-11-11:

Método	Escolha 2008–2018, 97,5%	Escolha, 99%	Confirmação 2019–2026, 97,5%	Confirmação, 99%
GARCH-FHS	**6 de 9**	**9 de 9**	**9 de 11**	**8 de 11**
GJR-GARCH(1,1)-t	0 de 9	0 de 9	0 de 11	1 de 11
Histórico	0 de 9	0 de 9	3 de 11	2 de 11

- **Escolha:** só com 2008–2018, a regra `choose_method` (mais setores a passar os três testes a 97,5%) escolhe a FHS. No período da escolha contam 9 setores, porque o XLRE e o XLC ainda não tinham previsões suficientes.
- **Confirmação:** em 2019–2026, que a escolha nunca viu e que inclui a COVID-19 e 2022, a FHS continua claramente à frente. A conclusão não depende de ter usado os mesmos dados.
- **Leitura honesta:** no período da escolha a FHS só passa os três testes a 97,5% em 6 de 9 setores; é o melhor método, não um método perfeito.

Testes múltiplos. Cada método é sujeito a 88 testes (11 setores × 2 níveis × 4 testes). A 5%, esperam-se cerca de 4,4 rejeições por acaso mesmo com um modelo certo, por isso uma rejeição isolada não condena um método. A correção de Holm (1979) controla a probabilidade de haver pelo menos um falso positivo, sem assumir independência entre os testes:

Método	Rejeições a 5% (de 88)	Depois da correção de Holm
GARCH-FHS	12	0
GJR-GARCH(1,1)-t	62	23
Histórico	67	42

A FHS tem mais rejeições do que as 4,4 esperadas por acaso (os testes não são independentes: o condicional combina os outros dois), mas nenhuma sobrevive à correção. Nos outros dois métodos sobrevivem dezenas.

Validação: `holm` é comparada com `statsmodels.stats.multitest.multipletests`; no teste dos períodos, a linha "total" é igual à do backtest sem divisão e as exceções dos dois períodos somam as do total.

K. Modelo oficial e previsão para o próximo dia útil (Sprint 4a)

O backtest escolhe o modelo oficial. Até 2026-11-12 foi a FHS; desde 2026-11-13 é a EVT condicional (`OFFICIAL_VAR_METHOD = "evt"`, secção 15). Os números desta secção são os da FHS, que serviram a primeira escolha. A 97,5%, o FHS passa o Kupiec em 11/11 setores, o Christoffersen em 10/11 e o Z2

em 10/11. O histórico só passa a independência em 1/11 e o GARCH-t passa o Kupiec em 1/11 e o Z2 em 0/11. A tabela completa está no comentário de `config/settings.py`.

Todos os dias, o pipeline grava em `data/features/official_risk.csv` o **VaR 99%, o VaR 97,5% e o ES 97,5% para o próximo dia útil** (`OFFICIAL_MEASURES`), com todos os dados disponíveis até hoje.

Sem lógica duplicada: a série de cada setor ganha um dia extra no fim, a sessão seguinte da NYSE (calendário com feriados, ver secção 10.A), com retorno 0. Corre-se o mesmo `sector_forecasts` do backtest: a última linha é a previsão de amanhã e as restantes são o backtest. O valor 0 é só um marcador, porque a previsão de um dia usa apenas dados até à véspera. Se esse dia for o primeiro de um mês, o GARCH é re-estimado com os dados até hoje, como no backtest.

Validação:

- a previsão feita com dados até $t-1$ coincide com a linha t do backtest completo (erro relativo $< 10^{-12}$), num dia de re-estimação, a meio do mês e no último dia;
- acrescentar o marcador não muda nenhuma linha anterior;
- no pipeline real, `var_backtest.csv` sai idêntico, byte a byte, ao de antes da alteração.

Leitura (previsão para 2026-11-10): o ES 97,5% oficial do XLK é 9,5%, o dobro do CVaR histórico de 3 anos (4,65%). O FHS escala a cauda pela volatilidade atual do GARCH, e o XLK acabou de ter dias de −8% e +3,7%. Nos setores calmos (XLU, XLC, XLRE), o ES oficial fica próximo ou abaixo do histórico. Este é o objetivo de um modelo condicional: o histórico pesa da mesma forma os 3 anos, enquanto o FHS reage ao regime de hoje.

🧩 7. Visão conjunta da carteira (Sprint 3)

Código: `src/models/portfolio.py` · parâmetros: `config/settings.py` (`PORTFOLIO_WEIGHTS`, `LW_*`, `STRESS_SCENARIOS`) · testes: `tests/test_portfolio.py`. Saídas: `data/features/risk_contribution.csv`, `stress_tests.csv` e `covariance_shrinkage.csv`.

Carteira de referência: pesos iguais nos 11 setores ($w_i = 1/11$), salvo indicação em contrário em `PORTFOLIO_WEIGHTS`. A carteira agrega-se em **retornos simples**, porque só aí $r_p = \sum_i w_i r_i$ é exato. Por isso, nesta secção, também a volatilidade usa retornos simples, o que é uma exceção à convenção dos setores individuais. A janela é a do resto do projeto: `CVAR_YEARS` = 3 anos.

A. Covariância de Ledoit-Wolf (2004)

Encolhe a covariância amostral S (de máxima verosimilhança, dividida por T) para a identidade escalada:

$$\hat{\Sigma} = \delta\, m\, I + (1-\delta)\, S, \qquad m = \tfrac{1}{N}\operatorname{tr}(S)$$

Com a norma $\|A\|^2 = \operatorname{tr}(AA^\top)/N$ e os retornos centrados x_t:

$$d^2 = \|S - mI\|^2, \quad \bar{b}^2 = \frac{1}{T^2}\sum_t \|x_t x_t^\top - S\|^2, \quad b^2 = \min(\bar{b}^2, d^2), \quad \delta = b^2/d^2$$

Para calcular $\overline{b}^2$ usa-se $\sum_t \|x_t x_t^\top - S\|_F^2 = \sum_t (x_t^\top x_t)^2 - T\|S\|_F^2$.

Avaliação fora da amostra: a carteira de variância mínima sem restrições, $w = \Sigma^{-1}\mathbf{1}/\mathbf{1}^\top\Sigma^{-1}\mathbf{1}$, é re-estimada no 1.º dia útil de cada mês só com os W dias anteriores, uma vez com S e outra com $\hat{\Sigma}$. Compara-se a volatilidade realizada no mês seguinte. A amostra comum aos 11 setores começa em 2018-06, com a entrada do XLC.

B. Contribuição para o risco (decomposição de Euler)

Uma medida homogénea de grau 1 nos pesos decompõe-se em $\rho(w) = \sum_i w_i\, \partial\rho/\partial w_i$:

- **Volatilidade** (com $\hat{\Sigma}$ de Ledoit-Wolf): $RC_i = w_i\,(\hat{\Sigma}w)_i/\sigma_p$, com $\sigma_p = \sqrt{w^\top\hat{\Sigma}w}$.
- **CVaR histórico:** sendo $\mathcal{T}$ o conjunto dos dias em que $r_p \le Q_{1-\alpha}(r_p)$, ou seja, os mesmos dias que `cockpit.cvar` usa, $RC_i = -w_i\,\overline{r_i}\big|_{\mathcal{T}}$. Como $\overline{r_p}|_{\mathcal{T}} = \sum_i w_i\overline{r_i}|_{\mathcal{T}}$, a soma das contribuições é exatamente o CVaR da carteira.
- **Rácio de diversificação:** $\sum_i w_i\rho_i/\rho_p$, a soma dos riscos isolados a dividir pelo risco da carteira. Um rácio de 1 quer dizer que não há diversificação.

C. Stress tests históricos

Três episódios, cada um do pico ao vale do SPY ajustado: **2008** (2007-10-09 → 2009-03-09), **COVID-19** (2020-02-19 → 2020-03-23) e **subida de juros** (2022-01-03 → 2022-10-12). Para cada setor, para a carteira e para o SPY calcula-se:

- a perda acumulada $1 - \prod_t(1 + r_t)$;
- o pior dia;
- o drawdown máximo dentro do episódio.

A carteira é **buy-and-hold** com os pesos no início do episódio, pelo que a perda $L_p = \sum_i w_i L_i$ é aditiva e a contribuição de cada setor é $w_i L_i$. O pior dia da carteira é também comparado com o CVaR atual, em múltiplos.

Proxy para setores sem história no episódio (XLRE e XLC em 2008): $r_{i,t} = \beta_i\, r_{SPY,t}$, com o β atual de `sector_metrics.csv` (3 anos). O proxy só capta a parte sistemática e ignora o risco específico, por isso é assinalado com `proxy` e com * no cockpit.

D. Validação

- A Ledoit-Wolf, tanto δ como $\hat{\Sigma}$, é comparada com `sklearn.covariance.LedoitWolf` (erro relativo $< 10^{-10}$), com T = 30, 63 e 400.
- A variância mínima é comparada com a solução fechada para Σ diagonal ($w_i \propto 1/\sigma_i^2$) e com perturbações aleatórias que mantêm $\sum w = 1$, nenhuma das quais pode baixar a variância.
- As contribuições de Euler somam a volatilidade e o CVaR da carteira, e a de volatilidade é comparada com a derivada numérica (diferenças finitas centradas).
- O stress test é comparado com um exemplo de 2 ativos calculado à mão, com proxy, buy-and-hold e pior dia da carteira.
- **Sem look-ahead** no teste fora da amostra: alterar os retornos a partir de t não muda nada antes de t.

E. Leitura dos resultados (dados até 2026-11-09)

- **Diversificação:** com pesos iguais, a volatilidade é 12,1% e o CVaR 97,5% é 2,21% a 1 dia. O rácio é 1,49× na volatilidade e só 1,39× no CVaR: nos piores dias os setores caem juntos e a diversificação encolhe.
- **Quem pesa na cauda:** o XLK, o XLY e o XLE contribuem para o CVaR mais do que o seu peso de 9,1% (12,9%, 12,4% e 11,0%). O XLP, o XLU e o XLV contribuem bastante menos (4,7–6,8%). O XLE pesa mais no CVaR (11,0%) do que na volatilidade (7,6%), porque as suas quedas coincidem com os piores dias da carteira.
- **Stress:** em 2008 a carteira perde 49,5% (SPY: 55,2%) e o maior contribuinte é o XLF. Na COVID perde **mais** do que o SPY (36,0% vs 33,7%), porque os pesos iguais dão à energia mais peso do que o índice. Em 2022 perde menos (17,2% vs 24,5%), porque o XLE subiu 44,5%. O pior dia da COVID equivale a 5,4× o CVaR atual, o que mostra que o CVaR de 3 anos não é um cenário de stress.
- **Ledoit-Wolf:** com T/N = 69 (3 anos) o encolhimento é pequeno ($\delta \approx 0{,}04$) e reduz a volatilidade fora da amostra em 2,2%. Com 63 dias ($T/N \approx 6$), $\delta \approx 0{,}27$ e o número de condição desce de 33 para 9, mas o ganho fora da amostra é marginal (0,2%). Com apenas 11 ativos a covariância amostral já está bem condicionada, e o benefício da Ledoit-Wolf vai crescer quando se descer ao nível das ações.

F. Cenário de stress próprio (cockpit)

O utilizador escolhe **um** choque instantâneo, no SPY ou num fator macro, e o efeito propaga-se pelos betas já medidos (`portfolio.shock_returns`):

- **Mercado:** $r_i = \beta_i \cdot \Delta_{SPY}$, com o beta diário de 3 anos em retornos simples (`sector_metrics.csv`).
- **Fator macro k:** $r_i = e^{\,b_{ik}x} - 1$, com o b_{ik} semanal da regressão HAC da secção 9 (retornos log do setor). Usam-se só as ligações aceites ($|t| \geq 2$); as outras contam 0. A variável é $x = \Delta$ em p.p. para juros, inflação e spreads, e $x = \ln(1 + \text{choque})$ para o VIX, o petróleo e o dólar.
- **Carteira:** $r_p = \sum_i w_i r_i$, com os pesos da secção 7. Mostra-se também em múltiplos do CVaR diário da carteira.

Limitações. É uma aproximação linear e não soma choques: os fatores estão correlacionados entre si e com o mercado, e somar os efeitos univariados contaria o mesmo risco duas vezes. Choques grandes extrapolam para fora da amostra em que os betas foram estimados e não captam o contágio próprio das crises. Para isso servem os cenários históricos da secção C.

🎯 8. Scorecard de risco por setor, 0–100 (Sprint 4b)

Código: `src/models/scorecard.py` · parâmetros: `config/settings.py` (`SCORE_*`, `STRESS_PROXY_WEIGHT`, `MOMENTUM_DAYS`, `MODEL_RISK_*`) · testes: `tests/test_scorecard.py`. Saídas: `data/features/scorecard.csv`, `scorecard_sensitivity.csv`.

A. Componentes (maior = mais risco)

Componente	Valor em bruto	Fonte	Peso
cauda	ES 97,5% do modelo oficial (secção 15) para o próximo dia útil	`official_risk.csv`	0,30
sistemico	% do CVaR da carteira ÷ peso (>1 = contribui mais do que pesa)	`risk_contribution.csv`	0,20
stress	perda média nos 3 cenários históricos, só perdas	`stress_tests.csv`	0,20
regime	percentil da vol 63d face à história do próprio setor	`sector_metrics.csv`	0,15
momento	exceções ao VaR 97,5% oficial nos últimos 60 dias	`var_backtest_series.parquet`	0,15

Normalização: cada componente vai para $[0, 1]$ pelo percentil entre os 11 setores, $c = (\text{posição} - 1)/(n - 1)$, com empates na posição média. Assim, o setor com o valor mais baixo vale 0 e o mais alto vale 1. O *regime* já é um percentil em $[0, 1]$ e não é re-normalizado.

Cauda face à história do próprio setor (v5.3, `SCORE_HIST_WEIGHT` = 0,5): só com a posição entre os 11, um score baixo quer dizer "o menos arriscado dos 11", mesmo num dia em que todos estão arriscados. Por isso a cauda passou a ser metade posição e metade história própria:

$$c_{i,\text{cauda}} = 0{,}5\,\frac{\text{posição}_i - 1}{n - 1} + 0{,}5\,\hat{F}_i(\text{ES}_i), \qquad \hat{F}_i(x) = \text{fração das previsões passadas do seto}$$

A história são as previsões do backtest do modelo oficial (desde 2008, ou desde que o setor existe). O regime já era um percentil na história própria; com esta mudança, 30% do peso do score é absoluto (15% da cauda e 15% do regime). Sistémico, stress e momento continuam relativos.

Stress com proxy: nos cenários em que o setor usa o proxy β × SPY (XLRE e XLC em 2008), a perda pesa `STRESS_PROXY_WEIGHT` = 0,5:

$$\text{stress}_i = \frac{\sum_s \omega_s \max(0, L_{i,s})}{\sum_s \omega_s}, \qquad \omega_s = 0{,}5 \text{ se proxy, } 1 \text{ caso contrário}$$

B. Score, risco de modelo e P × I

$$\text{score}_i = 100 \sum_k w_k\, c_{i,k}, \qquad \sum_k w_k = 1$$

Risco de modelo: o score é multiplicado pelo semáforo de Basileia do método oficial a 99%, o nível em que as zonas estão definidas: verde ×1,00, amarelo ×1,10, vermelho ×1,25. O resultado é o `score_final`, limitado a 100, e a flag `risco_modelo` fica ativa quando o semáforo não é verde. É um ajuste separado: o score mede o risco do setor; o multiplicador mede a confiança que podemos ter na medição.

Mapa: o **impacto** é o quintil (1–5, a mesma regra `quintile_score` do Sprint 1) da média ponderada de cauda, sistémico e stress. A **probabilidade** é o quintil da média ponderada de regime e momento, com os pesos de cada grupo re-normalizados.

Incerteza do ranking (v5.3): os pesos são uma escolha. Para ver quanto a posição de cada setor depende deles, sorteiam-se 5 000 conjuntos de pesos à volta dos oficiais, $w \sim \mathrm{Dirichlet}(20 \cdot w^{oficial})$ (o peso de 0,30 varia com desvio-padrão de cerca de 0,10), e recalcula-se o ranking. O `scorecard.csv` guarda `rank_p05` e `rank_p95` (as posições entre as quais o setor fica em 90% dos sorteios) e `p_top3`. Mede só a incerteza dos pesos, não a dos dados.

C. Validação

- O percentil na história própria e a mistura da cauda são verificados à mão; um setor pior em tudo fica em 1.º em todos os sorteios, e sem variação dos pesos o intervalo reduz-se à posição oficial.
- A normalização é testada nos extremos (o menor dá 0, o maior dá 1), nos empates e com o regime intacto.
- Os pesos têm de somar 1, e os grupos de impacto e de probabilidade são uma partição dos componentes. O score é também comparado com um cálculo à mão.
- **Monotonia:** piorar qualquer componente de qualquer setor nunca baixa o score desse setor, nem o impacto ou a probabilidade do grupo afetado. Um semáforo pior também nunca baixa o `score_final`.
- O proxy pesa metade, verificado à mão. O momento só conta a janela pedida.

D. Sensibilidade e leitura (2026-11-12)

- **Topo:** o XLK é o 1.º com folga (score 91) e fica em 1.º em todos os sorteios de pesos. Tem o maior ES previsto (8,2%, no percentil 97% da sua própria história), a maior contribuição para o CVaR por unidade de peso (1,42×) e a volatilidade no percentil 89%.
- **Logo abaixo:** XLY (72), XLE (69) e XLI (68) não se distinguem: os intervalos são 2–4, 2–5 e 2–4, e a probabilidade de estar no top 3 é 80%, 62% e 54%. A ordem entre eles depende dos pesos.
- **Fundo:** XLP, XLU, XLC e XLRE ficam entre o 7.º/8.º e o 11.º; a ordem entre eles também não é fiável.
- **Efeito da história própria:** o XLC tinha cauda 0 por ser o último dos 11; o seu ES de hoje está no percentil 27% da sua história, por isso a cauda passa a 0,14. O XLP sobe para 0,73: é dos menos arriscados dos 11, mas está alto face ao seu próprio passado.
- **Quebra na série:** as mudanças de 2026-11-13 (stress só com perdas, cauda com história própria) alteram o score sem que o mercado mude; os alertas desse dia sobre níveis P × I vêm daí.
- **Stress só com perdas (2026-11-13, `STRESS_ONLY_LOSSES`):** antes, a *perda média* deixava os ganhos compensar as perdas. O XLE subiu 44,5% em 2022 e ficava com o componente de stress mais baixo, apesar de ter perdido 48% e 56% nos outros dois cenários. Agora um ganho num cenário conta como perda zero: $\max(0, L_{i,s})$.

🔗 9. Ligações medidas entre fatores macro e setores (Sprint 4c)

Código: `src/models/factor_links.py` e `src/collect/download_factors.py` · parâmetros: `MACRO_FACTORS`, `LINK_*` · testes: `tests/test_factor_links.py`. Saídas: `data/features/factor_links.csv` (as 66 regressões).

A. Fatores

Nó no mapa	Série	Fonte	Variação semanal	Direção adversa
juros	DGS10 (Treasury 10Y)	FRED	Δ em p.p.	subir
inflacao	T10YIE (breakeven 10Y)	FRED	Δ em p.p.	subir
spreads	BAMLH0A0HYM2 (spread high yield); nas janelas longas, BAA10Y (spread Baa da Moody's sobre o Treasury 10Y)	FRED	Δ em p.p.	subir
vix	^VIX	Yahoo	Δ log	subir
petroleo	CL=F (WTI, futuro)	Yahoo	Δ log	subir
dolar	DX-Y.NYB (DXY)	Yahoo	Δ log	subir

Retornos semanais (sexta a sexta, com o último valor de cada semana). Reduzem o ruído da assincronia entre fontes: o FRED publica com 1 dia de atraso e os futuros fecham a horas diferentes das ações. A semana em curso, ainda incompleta, fica de fora. A janela é de `CVAR_YEARS` = 3 anos (156–157 semanas). Os setores usam retornos log semanais.

B. Regressão e erros-padrão HAC

Para cada setor i e fator k: $r_{i,t} = a + b\,\Delta f_{k,t} + \varepsilon_t$ por OLS. Os retornos semanais podem ter autocorrelação e heterocedasticidade, por isso os erros-padrão são de **Newey–West (HAC)**:

$$\widehat{V}(\hat{b}) = (X^\top X)^{-1}\,\hat{S}\,(X^\top X)^{-1}, \qquad \hat{S} = \sum_t \hat{u}_t\hat{u}_t^\top + \sum_{l=1}^{L}\left(1 - \frac{l}{L+1}\right)\sum_t\left(\hat{u}_t\hat{u}_{t-l}^\top + \hat{u}_{t-l}\hat{u}_t^\top\right)$$

com $\hat{u}_t = x_t\hat{\varepsilon}_t$, o núcleo de Bartlett e $L = \lfloor 4(T/100)^{2/9} \rfloor$ = 4 lags para T = 157.

C. Aceitação, sinal e intensidade

- **Aceite** se $|t| \geq$ `LINK_T_MIN` = 2.
- **Sinal** (a mesma convenção das ligações manuais do mapa): **+** se o movimento adverso do fator piora o setor ($\text{adverso} \cdot b < 0$); **–** se o melhora.
- **Intensidade** 1/2/3 pelos tercis de $|b_{pad}|$ entre as ligações aceites, com $b_{pad} = b\,\sigma_{\Delta f}/\sigma_r$, que numa regressão simples é a correlação.
- Guardam-se b, t, R^2 e n em cada ligação.
- **Contágio entre setores:** as 10 arestas da MST de `cockpit.mst`, sobre os retornos diários de 3 anos, com o tipo "contágio" (sem direção). A intensidade vem dos tercis da correlação.

D. Validação

- Com dados sintéticos de beta conhecido (+0,20, −0,30 e 0), a regressão recupera o beta (±0,03) e a significância ($|t| > 2$ quando há relação, $|t| < 2$ quando não há). O sinal segue a direção adversa e inverte quando a direção adversa se inverte.
- O erro-padrão HAC é comparado com a fórmula de Newey–West escrita à mão em numpy, com L = 0, 2 e 4 (erro relativo < 10^{-10}). Nota: o `statsmodels` usa o Newey–West clássico, sem a correção $n/(n-k)$.

- Também são testados o corte da semana incompleta, as transformações (Δ e Δ log, com níveis ≤ 0 → sem valor), o último valor de cada semana e a MST com $N - 1$ arestas.

E. Resultados (semanas 2023-11-10 → 2026-11-06)

> **Nota:** entre 2026-11-13 e 2026-11-14 o spread destas ligações foi o Baa da Moody's; com ele eram aceites só 31 ligações e as dos spreads ficavam com t até –3,7. Voltou-se ao high yield, que é o que mexe nas crises; o Baa ficou só onde é preciso história longa (ver F).

São aceites **33 das 66** ligações. Por fator:

Fator	Ligações aceites	Leitura
vix	10	O medo afeta todos os setores menos o XLE; mais o XLK (R^2 0,53) e o XLY, menos o XLP e o XLU (defensivos).
spreads	9	O crédito a alargar pesa mais no XLI, no XLF e no XLK ($t \approx -11$). O XLP e o XLU não são afetados.
dolar	5	O dólar forte pesa no XLB, no XLP, no XLV, no XLC e no XLRE (multinacionais e matérias-primas).
juros	4	A subida de juros pesa no XLRE (t = –4,1), no XLU e no XLP (setores "obrigacionistas") e ajuda o XLE.
inflacao	3	O breakeven a subir ajuda o XLE, o XLF e o XLI (reflação), por isso o sinal é –.
petroleo	2	O petróleo a subir ajuda o XLE (R^2 0,37) e pesa no XLY (consumo).

Comparação com as ligações manuais do mapa:

- confirmadas: juros → XLRE (+), juros → XLU (+), petróleo → XLE (–), petróleo → XLY (+), spreads → XLF (+), VIX → XLK (+);
- **não confirmadas** nestes 3 anos: juros → XLK (+), com t = 0,56, e juros → XLF (–), com t = 0,13.

Limitações:

- **Testes múltiplos:** com 66 testes a $|t| \geq 2$ (cerca de 5%), esperam-se ~3 ligações falsas mesmo sem relação nenhuma. As ligações com $|t|$ perto de 2 (dólar → XLRE, inflação → XLI) devem ser lidas com cautela.
- As regressões são **univariadas**: o VIX e os spreads estão muito correlacionados entre si, e cada beta capta também o efeito dos outros fatores.
- **Spread de crédito:** o CSV público do FRED só tem os últimos 3 anos do spread high yield (licença da ICE). Chega para as ligações (3 anos). O simulador de choques (10 anos) e o teste nas crises desde 2008 (secção 19) usam o spread Baa da Moody's (`BAA10Y`, desde 1986, coluna `spreads_longo`), que mede o crédito de qualidade média e reage menos do que o high yield.

F. No cockpit

- As ligações medidas aparecem por baixo da **Teia de risco** e na ficha de cada setor (secção 11).
- O mapa HTML autónomo do Sprint 4d, que as desenhava com ligações manuais e cadeia de impacto, foi apagado em 2026-11-13: o mapa de risco passou a ser só o do cockpit.

🤖 10. Bots, alertas e relatório semanal (Sprint 5)

O pipeline corre sozinho nos dias úteis às 22:30 (hora de Lisboa, depois do fecho dos EUA): `launchd` → `flows/pipeline.py` (Prefect).

A. Flow

- **Calendário da NYSE (`src/collect/sessao.py`):** os feriados são calculados pelas regras da bolsa, sem dependências:
  - data fixa (Ano Novo, Juneteenth desde 2022, Independência, Natal), passando para sexta se calharem ao sábado e para segunda se calharem ao domingo; o Ano Novo ao sábado não fecha a sexta;
  - data móvel (Martin Luther King, Presidents' Day, Sexta-feira Santa pela Páscoa, Memorial Day, Labor Day, Thanksgiving);
  - mais os fechos excecionais de `NYSE_SPECIAL_CLOSURES` (furacão Sandy, lutos nacionais).
  - **Validação:** de 2005-01-03 a 2026-11-11, as sessões do calendário coincidem dia a dia com as 5 500 sessões em que o SPY negociou. O teste repete a comparação com os 3 anos do snapshot no CI.
  - **Fechos antecipados (13:00 em NY):** 3 de julho, o dia a seguir ao Thanksgiving e a véspera de Natal, quando são dias de sessão. Nesses dias a sessão conta como fechada às 14:00 de NY. A regra reproduz os fechos antecipados de 2023 a 2025 publicados pela bolsa, mas não se consegue validar com preços diários, e a do 3 de julho teve exceções históricas.
  - **No cockpit:** a barra lateral mostra a última sessão fechada, a próxima sessão, os 3 próximos feriados e o próximo fecho antecipado, e avisa se os resultados do pipeline estiverem atrás da última sessão.
  - **Onde se usa:** na sessão esperada (cache e alerta de dados atrasados), na data da previsão oficial (secção 6.K) e no dia do relatório semanal e da publicação.
- **Horizontes (Fase E):** a task Backtester corre também `horizonte.main()`: previsão todos os dias, backtest dos horizontes só na última sessão da semana.
- **Uma task por bot:** Coletor → Inspetor → Modelador → Backtester → Backtester de empresas → Carteira → Scorecard → Ligações → Cauda → Sentinela → Relatório → Snapshot → Publicador.
- **Publicador (`src/report/publicar.py`):** na última sessão de cada semana (normalmente sexta), depois do run, envia o snapshot (`data/snapshot/`, fora do Git) para o ramo `snapshot` como um único commit sem pai, que substitui o anterior com um push forçado só desse ramo. O `main`, o índice e os ficheiros locais não são tocados, e o Publicador recusa-se a substituir o ramo de trabalho. Sem alterações não há commit. Se o push falhar, o erro vai para o log e chega uma notificação; o resto do run não é afetado e o run seguinte volta a tentar. O cockpit do Streamlit Cloud descarrega esse ramo de 6 em 6 horas; se faltar um ficheiro ou não houver rede, usa a cópia embutida em `app/cockpit/snapshot/`. Até 2026-11-13 o snapshot ia para o `main` todas as semanas, o que fazia o repositório crescer cerca de 5 MB por semana.
- **Snapshot (Sprint 6):** copia para `app/cockpit/snapshot/` (versionado, cerca de 2,7 MB) os preços dos ETFs e das empresas do mapa de risco (5 anos, desde a secção 13), o Treasury 10Y e os resultados que o cockpit lê. Assim o cockpit corre sem rede, por exemplo no Streamlit Community Cloud. As séries do backtest são gravadas em float32, o que dá um erro relativo de cerca de 10^{-7}, sem efeito nas exceções mostradas.

- **Coletor:** 2 novas tentativas, 5 minutos entre elas, e cache pela **última sessão de Nova Iorque já fechada** (17:00 hora de NY, 1 h depois do fecho, `src/collect/sessao.py`). Dois runs que esperam a mesma sessão descarregam os dados uma só vez, e a cache só é usada se os preços já chegarem a essa sessão. Se o download correr mas os preços vierem atrasados, o Coletor repete-o até 3 vezes, com 10 minutos entre elas; se continuarem atrasados, o flow segue e o Sentinela alerta. A chave não pode ser a data do calendário: um run de madrugada em Lisboa ainda só tem a sessão da véspera e bloquearia o run das 22:30 desse dia (aconteceu a 2026-11-11).
- **Paragem em caso de falha:** as tasks correm em sequência. Se o contrato do Inspetor falhar, a exceção pára o flow e nada a jusante corre, por isso nunca se publica um mapa ou um alerta calculado com dados inválidos.
- **Fatores macro no Inspetor:** passam a ter contrato pandera: uma coluna por fator, valores finitos, datas únicas e ordenadas. Os níveis <= 0 em séries com variação logarítmica são sinalizados sem ser apagados (o WTI de –37,63 a 2020-04-20 fica de fora pelo `logdiff`). A data do último valor de cada fator vai para `quality_report.md`, porque as séries do FRED chegam com 1 dia de atraso.

B. Bot Sentinela (`src/report/alerts.py`)

Em cada run grava um estado compacto do dia em `data/state/estado_<data>.json`: score, semáforo, P × I, perda e VaR/ES oficiais, ligações aceites e regime de juros. Depois compara-o com o último estado de uma data anterior.

Alerta	Regra	Severidade
Semáforo	muda o semáforo de Basileia (VaR 99% do modelo oficial, 250 dias)	piora para vermelho: alta; piora para amarelo: média; melhoria: baixa
Exceção	perda do dia > VaR 97,5% oficial previsto com dados até t–1	média; alta se também > ES 97,5%
Nível P × I	muda o nível de P × I: baixo ≤ 4, moderado ≤ 9, elevado ≤ 16, crítico ≤ 25	sobe para crítico: alta; outra subida: média; descida: baixa
Ligação medida	uma ligação fator → setor passa a ser aceite (|t| ≥ 2) ou deixa de o ser	entra: média; sai: baixa
Regime de juros	muda o regime do Treasury 10Y (variação em 63 dias úteis)	para subida: alta; outra mudança: média
Dados atrasados	os preços acabam antes da última sessão de NY já fechada (falha na coleta; os feriados já estão no calendário)	alta

- **Exceções:** precisam só do próprio dia, por isso também saem no primeiro run.
- **Alertas.md:** o Sentinela escreve `Risco Setorial/Alertas.md`, com uma secção por data e a mais recente no topo. Cada alerta tem campos inline do Dataview (`[severidade:: alta]`). Repetir o run do mesmo dia reescreve a secção, sem duplicar.
- **Notificação:** só os alertas de severidade alta geram uma notificação macOS (`osascript`).
- **Limitação:** o nível P × I usa quintis entre os 11 setores, por isso um setor pode mudar de nível sem que o seu score se mexa, apenas porque outro mudou de posição. Ex.: XLI a 2026-11-10, P×I 16 → 20 com score 69,3 → 69,2.

C. Relatório semanal (`src/report/weekly.py`)

- **Quando:** sai na última sessão da NYSE de cada semana: normalmente sexta, quinta se a sexta for feriado, como a Sexta-feira Santa (ou com `--semanal`), e é gravado em `Risco Setorial/Semana AAAA-Www.md`.
- **Conteúdo:**
  - top 3 do scorecard, com a variação de score e de posição;
  - exceções ao VaR 97,5% oficial na semana, face às esperadas (2,5% × dias × 11);
  - ligações que entraram ou saíram;
  - cenário de stress mais severo para a carteira e o setor mais atingido nesse cenário.
- **Referência:** o último estado da semana anterior; na primeira semana com estados, o primeiro estado da própria semana.
- **Painel:** o frontmatter (`tipo: relatorio-semanal`, `semana`, `top3`, `excecoes`, …) alimenta `00 Painel.md`, que agrega relatórios semanais, alertas recentes e logs diários do cockpit.

D. Validação

`tests/test_alerts.py` (22 testes) usa estados sintéticos de ontem e de hoje e cobre:

- cada tipo de alerta e as suas severidades, em ambos os sentidos;
- que não há alertas quando nada muda e que as exceções saem mesmo sem estado anterior;
- a idempotência de `Alertas.md` e o corte das secções antigas;
- a notificação só para severidade alta;
- a escolha do estado de referência;
- a semana ISO, as exceções da semana e o cenário de stress mais severo.

---

11. Mapa de risco: setor → empresas → ficha da empresa

O mapa de risco é um só e vive no cockpit (separador **Teia de risco**, desde a Fase 4; a teia descrita na secção 19 substituiu o desenho em Plotly descrito aqui). Parte da espinha de contágio (MST das correlações entre setores, secção 2) e desce dois níveis.

A. Empresas de cada setor

- **Universo:** as `HOLDINGS_TOP` = 10 maiores posições de cada ETF, com o peso no ETF (Yahoo Finance, dados do fundo), num total de 110 empresas. Somam entre 37% (XLI) e 78% (XLE) do setor. Ficam em `data/features/holdings.csv` e são atualizadas pelo Coletor em cada run.
- **Falhas:** se o Yahoo falhar num setor, mantêm-se as posições do ficheiro anterior; sem ficheiro, usam-se as 4 ações de `SECTOR_PROFILE` com pesos iguais.

B. Setor aberto

- **Ficha do setor:** com um setor aberto e nenhuma empresa escolhida, o painel mostra o score e os seus componentes face à mediana, os fatores macro que o agravam ou atenuam, os vizinhos de contágio, o retorno nas crises e, numa secção que abre, o risco previsto desde 2008 e o backtest do modelo nesse setor.

- **Desenho:** o setor vai para o centro, as suas empresas ficam num anel interior e os outros setores num anel exterior, pela ordem angular que tinham no mapa. Só se desenham as ligações de contágio do setor aberto.
- **Empresa:** o tamanho do círculo é o peso no ETF; a cor é o rácio entre o CVaR 97,5% da empresa e o do ETF (verde ≤ 1×, vermelho ≥ 2,5×), na janela escolhida na barra lateral.
- **Ligações entre empresas:** ao escolher uma empresa, mostram-se as suas arestas na MST das correlações entre as empresas do setor, ou seja, as que mais se movem com ela.
- **Métricas:** CVaR histórico, downside beta, beta, correlação com o ETF e volatilidade anual, com as mesmas funções dos setores (`cockpit.cvar`, `cockpit.tail_table`).

C. Ficha da empresa

- **Bolsa:** preço e variação do dia, capitalização, PER, intervalo de 52 semanas, dividendo e recomendação dos analistas, do Yahoo Finance.
- **Notícias:** as `COMPANY_NEWS` = 6 mais recentes, com fonte, hora (UTC) e ligação.
- **Origem:** ao vivo, com cache de 15 minutos. Se o Yahoo falhar, ou no modo snapshot, usa-se `app/cockpit/snapshot/companies.json`, gravado no último run; a ficha indica sempre a origem.
- **Ligação direta:** `?setor=XLK&empresa=NVDA` abre o mapa já nesse setor e nessa empresa.

D. Limitações

- As medidas da janela (CVaR histórico, betas, correlações) são descritivas. A previsão e o backtest por empresa estão nas secções 13 e 15: o modelo oficial está validado em 76 de 109 empresas.
- Com 10 empresas por setor, o mapa não cobre o setor todo, e a MST entre empresas só vê essas 10.
- As posições e os pesos são os atuais: aplicá-los a 3 anos de preços ignora mudanças na composição dos ETFs.
- A ficha e as notícias dependem do Yahoo Finance, sem garantia de serviço; os textos vêm em inglês.

💼 12. Carteira do utilizador

Separador **Minha carteira** do cockpit; cálculo em `src/models/carteira.py` (funções puras) · testes: `tests/test_carteira.py`.

A. Carteira

- **Ativos:** as 110 empresas do mapa de risco, os 11 ETFs setoriais e o SPY, até `USER_PORTFOLIO_MAX` = 25 posições, só com pesos positivos (sem vendas a descoberto). Os pesos são ajustados em proporção para somar 100%.
- **Onde se guarda:** no endereço da página (`?carteira=NVDA:40,JPM:30,XLU:20,SPY:10`), sem contas de utilizador. Entradas inválidas ou fora do universo são ignoradas.

B. Medidas

- **Risco da carteira:** volatilidade anual (covariância Ledoit-Wolf) e CVaR 97,5% histórico a 1 dia, na janela escolhida, com as mesmas funções da carteira de referência (secção 7).
- **Contribuições de Euler:** a parte de cada posição no CVaR, $RC_i = -w_i\,\overline{r_i}|_{\mathcal{T}}$, soma exatamente o CVaR da carteira. O rácio "risco / capital" é $(RC_i/\mathrm{CVaR}_p)/w_i$: acima de 1, a posição pesa mais no risco do que no dinheiro investido.
- **Beta e downside beta** da carteira face ao SPY; o beta é a média ponderada dos betas das posições.
- **Exposição por setor:** cada empresa conta no seu ETF (no de maior peso, se estiver em dois), cada ETF no próprio setor e o SPY em "Mercado".
- **Score de risco setorial:** média dos scores dos setores (secção 8) ponderada pela exposição; só conta a parte investida em setores.

C. Stress

- **Cenários históricos:** $L_p \approx \sum_s e_s L_s$, em que e_s é a exposição ao setor s e L_s a perda desse setor no episódio (secção 7.C). Cada posição leva a perda do seu setor.
- **Choque no mercado:** $r_p = \sum_i w_i \beta_i \Delta_{SPY}$ (secção 7.F), com os betas da janela escolhida.

D. Limitações

- As contribuições, a exposição e o stress são **históricos e descritivos**. O VaR e o ES previstos da carteira vêm do modelo oficial, com um backtest curto da própria carteira (secção 13.C).
- O stress histórico ignora o risco específico de cada empresa, pelo que **subestima** carteiras concentradas em poucas ações.
- O universo são as 10 maiores posições de cada ETF; não há obrigações, ações fora dos EUA nem outras classes de ativos.
- Pesos fixos: não há histórico de transações nem re-equilíbrio.

F. Ações fora do mapa (Fase 5)

A carteira aceita qualquer ticker do Yahoo Finance, não só as 110 empresas do mapa. Escreve-se o ticker (ou põe-se no link, `?carteira=ASML:20,SAP.DE:15`) e o cockpit:

- **Valida-o no Yahoo** (`empresas.validar_ticker`): tenta o ticker tal como foi escrito, porque o sufixo da bolsa usa um ponto (SAP.DE), e depois no formato norte-americano (BRK.B → BRK-B).
- **Atribui-lhe um setor:** o ETF da classificação do Yahoo (`YAHOO_SETOR_ETF`; ASML → XLK). Sem classificação (um ETF de ouro, por exemplo) fica ligado ao mercado.
- **Calcula ao vivo:** o risco da carteira usa os preços do Yahoo, como antes. No simulador de choques (secção 19), estima-se o beta semanal da ação ao seu ETF (ou ao mercado) em 10 anos e sorteiam-se os seus resíduos nas mesmas semanas que os outros. Exemplo: ASML β = 1,17 ao XLK, SAP.DE 0,58, GLD 0,18 ao mercado.
- **Na teia:** aparece no anel do seu setor, com contorno branco, e entra na lista das empresas desse setor ("fora do ETF"); um clique abre a ficha com bolsa e notícias, como as do mapa (sem previsão nem backtest, que só existem para as do pipeline).

- **No pipeline diário:** só as que estiverem em `EXTRA_TICKERS` (`config/settings.py`). Entram em `holdings.csv` com peso 0 e passam a ter preços, modelo, backtest e quedas conjuntas, como as do mapa.

Limitações: uma ação cotada noutra moeda (SAP.DE em euros) traz o risco cambial dentro dos retornos; sem rede (modo snapshot) as ações fora do mapa não têm preços e ficam de fora.

E. Carteira alternativa por Hierarchical Risk Parity (v5.0)

Código: `src/models/carteira.py` (`calcular_pesos_hrp`, `hrp_quasi_diag`, `hrp_recursive_bisection`) · parâmetros: `HRP_RISK_MEASURE`, `HRP_MIN_DAYS`, `HRP_LINKAGE` · testes: `tests/test_carteira.py`.

O separador **Minha carteira** propõe outros pesos para os mesmos ativos, pelo algoritmo de López de Prado (2016), com a distância da secção 14 em vez da correlação:

1. **Distância:** $d_{AB} = 1 - \hat{p}_{AB}$, em que $\hat{p}_{AB}$ é a frequência com que A e B estão juntos nos 5% piores dias (`cauda.joint_crash`), calculada nos retornos da própria carteira, que pode misturar empresas, ETFs e SPY.
2. **Árvore e ordem:** agrupamento hierárquico (`single linkage`) sobre d; a ordem das folhas põe lado a lado os ativos que caem juntos.
3. **Bisseção recursiva:** a lista ordenada é cortada ao meio, vezes sem conta. Em cada corte, com R_1 e R_2 o risco de cada metade:

$$\alpha_1 = 1 - \frac{R_1}{R_1 + R_2}, \qquad \alpha_2 = 1 - \alpha_1$$

   O risco de cada metade é o CVaR 97,5% histórico (`cockpit.cvar`) da sub-carteira com pesos inversos à variância (covariância de Ledoit-Wolf). Com `HRP_RISK_MEASURE = "variance"`, usa-se a variância dessa sub-carteira.

- **Casos-limite:** um só ativo recebe peso 1; com menos de `HRP_MIN_DAYS` = 252 dias comuns não há sugestão.
- **Validação:** os pesos somam 1 e são não negativos nas duas medidas; com dois ativos, o resultado é a paridade de risco pelo CVaR calculada à mão; com A e B a cair juntos em mais de 90% dos piores dias e C independente e calmo, $w_C > w_A + w_B$.
- **Exemplo (NVDA 30%, MSFT 20%, JPM 20%, XOM 15%, XLU 15%; 3 anos até 2026-11-12):** o CVaR 97,5% desce de 3,47% para 2,29% (–34%) e a volatilidade anual de 19,5% para 12,9%.
- **Fora da amostra (Fase 6):** `carteira.hrp_fora_da_amostra` recalcula os pesos HRP de 63 em 63 dias só com os 504 dias anteriores e mantém-nos até ao recálculo seguinte; compara com os pesos do utilizador e com pesos iguais nos mesmos dias. Na carteira do exemplo, em 750 dias desde 2023-11-17: CVaR 97,5% da HRP 2,56%, da carteira 3,47% e de pesos iguais 2,95%; volatilidade anual 13,7%, 19,7% e 16,2%. A redução fora da amostra (–26% no CVaR) é menor do que a calculada na mesma amostra (–34%), como se esperava, mas continua. Validação: mexer nos retornos depois de um recálculo não muda os pesos até lá.
- **Limitações:** os números da mesma amostra são otimistas (o cockpit mostra os dois); o teste fora da amostra cobre só 3 anos, sem uma crise como 2008 ou 2020. O método não usa retornos esperados, custos nem impostos, e o corte ao meio segue a ordem das folhas, não os ramos da

árvore. É uma leitura de risco, não aconselhamento de investimento.

🏢 13. Modelo de risco por empresa e previsão da carteira

Código: `src/models/backtest_empresas.py` · testes: `tests/test_backtest_empresas.py` · saídas: `company_backtest.csv` e `company_risk.csv`.

A. O mesmo backtest, empresa a empresa

- **Sem lógica nova:** corre-se `backtest.run` (secção 6) sobre as empresas do mapa: histórico, GJR-GARCH(1,1)-t, FHS e, desde a Fase B, EVT (secção 15), com previsões feitas só com dados até à véspera e os mesmos testes.
- **Dados:** preços desde `COMPANY_START` = 2015, validados pelo Inspetor. Com a janela de 756 dias, as previsões começam em 2018 (mediana de 2 226 dias por empresa) e apanham a COVID-19 e 2022, mas não 2008.
- **Sem modelo:** empresas com menos de `COMPANY_MIN_DAYS` = 816 dias de preços ficam só com o risco histórico (hoje, a GEV).

B. Resultados (109 empresas, dados até 2026-11-11)

Número de empresas em que o teste **não rejeita** o modelo a 5%:

Método	Kupiec 97,5%	Christoffersen 97,5%	Condicional 97,5%	Z2 (ES) 97,5%	Kupiec 99%	Christoffersen 99%	Condicional 99%	Z2 (ES) 99%
GARCH-FHS	**86**	**96**	**91**	**69**	**98**	**101**	**97**	**88**
GJR-GARCH(1,1)-t	43	94	52	24	59	104	69	32
Histórico	79	39	32	64	80	46	44	63

- **A FHS continua a ser o melhor método,** mas com menos folga do que nos setores: passa os três testes a 97,5% (Kupiec, Christoffersen e Z2) em **61 de 109** empresas, contra 22 do GARCH-t e 21 do histórico.
- **Onde falha:** em 40 empresas o Z2 rejeita com $Z_2 < 0$, ou seja, o **ES fica subestimado**. Uma ação isolada tem saltos (resultados, notícias) que nem o GARCH nem os resíduos passados antecipam e que um setor dilui. A taxa média de exceções a 97,5% é 2,98%, acima dos 2,5%.
- **Semáforo a 99%:** 87 empresas em verde e 22 em amarelo; nenhuma em vermelho.
- **Consequência:** cada empresa leva duas marcas em `company_risk.csv`: `validado` (passa os três testes a 97,5%) e `es_subestimado`. O cockpit mostra-as na ficha e na tabela do setor.

Correção do ES subestimado. O Z2 é linear em $1/\mathrm{ES}$: multiplicar o ES previsto por k dá $Z_2' = 1 - (1 - Z_2)/k$. Por isso $k = 1 - Z_2$ é exatamente o fator que teria posto o Z2 a zero no backtest. Quando o Z2 rejeita com $Z_2 < 0$:

$$\mathrm{ES}^{aj} = k \cdot \mathrm{ES}, \qquad k = \min(1 - Z_2,\ \texttt{ES_ADJ_MAX} = 1{,}5)$$

- Só agrava: sem rejeição, ou com $Z_2 \geq 0$, $k = 1$. Nas 40 empresas corrigidas, k é em média 1,31.
- O VaR não é corrigido: a correção trata o tamanho das perdas, não a sua frequência.
- **Limitação:** k é calibrado no mesmo backtest que o justifica (dentro da amostra). Corrige o que o passado mostrou, não garante o futuro.

Cadência. O backtest completo das empresas demora cerca de 3 minutos e 20 segundos, por isso só corre na última sessão de cada semana, ou quando as empresas mudam (`COMPANY_FULL_WEEKLY`). Nos outros dias refaz-se apenas a previsão para a sessão seguinte, com uma ou duas estimações do GARCH por empresa (6 segundos no total). O semáforo e as marcas ficam então com até uma semana de atraso.

C. Previsão da carteira do utilizador

- **Método:** aplica-se o modelo oficial aos retornos da própria carteira com os pesos atuais, $r_{p,t} = \sum_i w_i r_{i,t}$ em cada dia passado (modelo oficial sobre a carteira com pesos constantes). O GARCH é estimado sobre r_p com a mesma janela e as mesmas regras (`backtest.next_day_forecast`).
- **Porquê assim:** o VaR e o ES não são aditivos; somar as previsões das posições ignoraria a diversificação. Modelar r_p diretamente capta-a sem estimar correlações dinâmicas.
- **Dados:** 5 anos de preços (`USER_FORECAST_YEARS`), nos dias em que todas as posições têm preço. Sem 756 dias + 1 mês em comum, não há previsão.
- **Backtest da própria carteira:** o cockpit corre `backtest.run` sobre r_p e mostra as exceções, os testes de Kupiec, Christoffersen e Z2, o semáforo e o gráfico. Se o Z2 rejeitar com $Z_2 < 0$, aplica-se a mesma correção $k = 1 - Z_2$ ao ES da carteira.
- **Limitações:** com 5 anos de preços e a janela de 756 dias, sobram cerca de 500 dias de previsões (2 anos), sem nenhuma crise: os testes só apanham falhas grandes. Pesos constantes no passado não são a história real da carteira.

D. Validação

- `resumo_metodos` e `validado` contra um exemplo feito à mão.
- A previsão da carteira é igual a correr `next_day_forecast` diretamente sobre $\sum_i w_i r_i$; o ES da carteira fica abaixo da soma ponderada dos ES isolados (diversificação); com uma posição de histórico curto, devolve "sem previsão".
- Com um ES sintético 1,4× abaixo do real, o ES corrigido por $k = 1 - Z_2$ dá $Z_2 = 0$ (erro < 10^{-12}).
- A previsão diária rápida difere da do backtest completo em menos de 1% (só muda o ponto de partida do otimizador do GARCH).
- No backtest da carteira, as exceções contadas na série coincidem com as da tabela de testes.

🌊 14. Dependência de cauda: quem cai com quem (Fase A)

Código: `src/models/cauda.py` · parâmetros: `CAUDA_*` · testes: `tests/test_cauda.py` · saídas: `tail_dependence.csv` e `tail_meta.json`. Segue McNeil, Frey e Embrechts (2005), capítulo 5.

A. Porque não basta a correlação

A correlação linear mede o andamento conjunto em dias normais. Para o contágio interessa outra pergunta: quando um setor tem um dia muito mau, o outro também tem? Na cópula de Gauss, a resposta no limite é "não", para qualquer correlação abaixo de 1. Um mapa feito só de correlações subestima por isso as quedas conjuntas.

B. Duas medidas

- **Quedas conjuntas observadas:** com a cauda de cada série definida como os q = 5% piores dias (retornos simples, 3 anos),

  $$\hat{p}_{AB} = \frac{\#\{t : A_t \text{ e } B_t \text{ na cauda}\}}{\#\{t : A_t \text{ na cauda}\}}$$

  É simétrica, porque as duas caudas têm a mesma probabilidade q. Sob independência vale cerca de 5%.
- **Coeficiente de dependência de cauda da cópula t:**

  $$\lambda = 2\, t_{\nu+1}\left(-\sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}}\right)$$

  É o limite da probabilidade condicional quando a cauda fica cada vez mais extrema. A cópula é ajustada assim:
  1. resíduos padronizados de um GJR-GARCH(1,1)-t por série, para tirar os clusters de volatilidade;
  2. $\rho_{ij} = \sin(\pi\tau_{ij}/2)$ a partir do tau de Kendall de cada par, com a matriz corrigida para ser definida positiva;
  3. um ν comum por máxima verosimilhança nas pseudo-observações (postos a dividir por $n+1$).

C. No mapa de risco

- As ligações do mapa passam a ser, por omissão, a árvore geradora mínima das **quedas conjuntas** (distância $1-\hat{p}$), entre os 11 setores e entre as 10 empresas de cada setor. A correlação fica como alternativa.
- Cada ligação mostra a frequência de quedas conjuntas, o λ e a correlação. A ficha do setor e a da empresa dizem com quem cada um cai junto.
- O separador Minha carteira usa a mesma espinha.

D. Resultados (dados até 2026-11-11)

- **Setores:** ν = 9,6. Os pares que mais caem juntos são XLY–XLC (54%), XLF–XLY (51%), XLI–XLB e XLI–XLY (49%), contra 5% por acaso.
- **O que a correlação esconde:** o XLK–XLC está no top 10 das quedas conjuntas, mas é só o 17.º par por correlação (0,54). O centro do mapa muda: pelas quedas conjuntas é o XLY (consumo discricionário); pela correlação eram o XLI e o XLRE.
- O λ é baixo (0,11 a 0,21 nos pares de topo): com ν perto de 10, a dependência no limite extremo é moderada. A frequência observada a 5% é bem mais alta, porque mede uma cauda menos extrema.

E. Validação

- `lambda_t` reproduz os 11 valores da tabela 5.1 do livro (erro < 0,005).
- A verosimilhança da cópula t é igual à calculada com `scipy.stats.multivariate_t`.
- Com dados simulados de uma t bivariada (ρ = 0,5, ν = 4), o ajuste recupera ρ (±0,04), ν (±1,2) e λ ; com dados gaussianos dá ν > 25 e λ < 0,03.
- Quedas conjuntas: séries iguais dão 1, opostas dão 0 e independentes dão cerca de q.

F. Limitações

- **Poucos dias de cauda:** 5% de 751 dias são cerca de 38 dias por série. Cada frequência tem um erro-padrão de uns 8 pontos percentuais; diferenças pequenas entre pares não são significativas.
- **Três anos sem crise sistémica:** a janela não inclui 2008 nem 2020. A dependência de cauda numa crise a sério é provavelmente maior.
- **Um só ν por grupo:** a cópula t tem a mesma cauda para todos os pares e é simétrica (quedas e subidas conjuntas iguais). Nos dados reais, as quedas conjuntas costumam ser mais fortes do que as subidas.
- **A árvore deixa ligações de fora:** mostra as N − 1 mais fortes que ligam tudo; a matriz completa está no cockpit.

G. Janelas de 1, 3, 5 e 10 anos (v5.5)

A Teia de risco deixa escolher a janela. `cauda.fit_windows` repete o ajuste para cada janela de `CAUDA_JANELAS`; a de 3 anos continua em `tail_dependence.csv` e as outras vão para `tail_dependence_janelas.csv` (coluna `anos`).

- **Quem entra:** uma série entra numa janela se tiver dados em pelo menos 80% dos dias (`CAUDA_MIN_COBERTURA`). As contas usam os dias em que todas têm preço: na janela de 10 anos os setores começam com o XLC, em junho de 2018 (2 112 dias).
- **Cauda com 1 ano:** os 5% piores dias seriam cerca de 12, poucos demais; usa-se q = 10% (25 dias), e o acaso passa a ser 10%.
- **Dados:** os preços das empresas e os fatores passaram a ser descarregados desde 2005, e o backtest das empresas também começa em 2005 (previsões desde 2008; ver secção 15).

Janela	q	Dias comuns	Quedas conjuntas, média dos 55 pares	Par mais ligado
1 ano	10%	250	22% (acaso: 10%)	XLU–XLRE 52%
3 anos	5%	752	28%	XLY–XLC 54%
5 anos	5%	1 253	35%	XLY–XLC 58%
10 anos	5%	2 112	44%	XLF–XLI 69%

Leitura: quanto mais longa a janela, mais os setores caem juntos, porque entram crises em que quase tudo cai ao mesmo tempo (2022 nos 5 anos; a COVID-19 nos 10). Num ano calmo a ligação mais forte é entre os setores sensíveis aos juros (utilities e imobiliário); em 10 anos é entre os cíclicos (financeiro e indústria). A janela muda também a Minha carteira e a Análise ao vivo; o modelo oficial, o score e o backtest usam sempre 3 anos.

🎯 15. EVT condicional e mudança do modelo oficial (Fase B)

Código: `backtest.py` (`gpd_tail`, `gpd_quantile`, `gpd_es`, `mcneil_frey`) · parâmetros: `EVT_*`, `BT_MF_NBOOT` · segue McNeil e Frey (2000) e McNeil, Frey e Embrechts (2005), secções 7.2.3, 7.2.6 e 4.4.3.

> **Desde 2026-11-13, o modelo oficial é a EVT condicional** (`OFFICIAL_VAR_METHOD = "evt"`). Onde as secções anteriores falam da FHS como modelo oficial, leia-se o modelo oficial em vigor; os números dessas secções são os da data indicada em cada uma.

A. Método

Usa o mesmo GARCH da FHS (mesmos μ_t e σ_t). Muda só a cauda dos resíduos padronizados:

- As perdas padronizadas $y = -\hat{z}$ acima de um limiar u seguem uma distribuição de Pareto generalizada $G_{\xi,\beta}$, ajustada por máxima verosimilhança. O limiar deixa `EVT_TAIL_FRAC` = 10% da janela na cauda (cerca de 75 excessos em 756 dias; no livro, 100 em 1 000).
- Quantil e expected shortfall da perda padronizada, com $\bar{F}(u)$ = fração na cauda e $p = 1 - \alpha$:

$$q_\alpha = u + \frac{\beta}{\xi}\left[\left(\frac{p}{\bar{F}(u)}\right)^{-\xi} - 1\right], \qquad \mathrm{ES}_\alpha = \frac{q_\alpha}{1-\xi} + \frac{\beta - \xi u}{1-\xi}$$

- $\mathrm{VaR}_t = -\left(e^{\mu_t - \sigma_t q_\alpha} - 1\right)$. O ES em retorno simples é a média de $-\left(e^{\mu_t - \sigma_t q} - 1\right)$ sobre 400 quantis igualmente espaçados da cauda, como no GARCH-t.
- **Porque ajuda:** a FHS estima o quantil de 2,5% com cerca de 19 resíduos; a Pareto usa os 75 piores e extrapola de forma suave, o que estabiliza o VaR e o ES extremos.

B. Teste de McNeil–Frey ao ES

Nos dias de exceção, $R_t = (L_t - \mathrm{ES}_t)/\mathrm{ES}_t$ deve ter média zero. Testa-se H_1: média > 0 (ES subestimado) por bootstrap da estatística t com os resíduos centrados (2 000 reamostragens), coluna `p_mf`. Ao contrário do Z2, olha só para o **tamanho** das perdas nas exceções e não para a sua frequência. Fica como segundo teste do ES; a regra de escolha continua a usar o Z2.

C. Resultados (dados até 2026-11-12)

Séries que passam os três testes (Kupiec, Christoffersen e Z2) a 97,5%:

Método	Escolha 2008–2018	Confirmação 2019–2026	Amostra toda	Empresas (de 109)
GARCH-EVT	**9 de 9**	**10 de 11**	9 de 11	**76**
GARCH-FHS	6 de 9	9 de 11	9 de 11	55
GJR-GARCH(1,1)-t	0 de 9	0 de 11	0 de 11	26
Histórico	0 de 9	3 de 11	1 de 11	8

As colunas das empresas usam previsões desde 2008 (desde 2026-11-14; antes começavam em 2018 e davam EVT 75, FHS 61, GARCH-t 22 e histórico 21). Com 2008 e a COVID-19 dentro da amostra, o histórico afunda (reage tarde às crises) e a EVT fica igual.

- **Decisão:** a regra `choose_method`, aplicada só a 2008–2018, escolhe a EVT; o período de confirmação e as empresas concordam. Por isso passou a modelo oficial.
- **Setores:** na amostra toda a EVT e a FHS empatam (9 de 11). A EVT tem menos exceções a 97,5% (2,62% contra 2,75%, para 2,5% esperados) e corrige o XLE a 99% (51 exceções contra 64, para 47 esperadas), cujo semáforo passou de amarelo a verde.
- **Empresas:** o ES subestimado fica em 17 empresas (FHS: muitas mais). Essas 17 mantêm a correção $k = 1 - Z_2$ (secção 13), em média ×1,22.
- **O que não melhora:** o teste de McNeil–Frey rejeita a EVT em 13 empresas e a FHS em 6. A EVT acerta melhor a frequência, mas nessas empresas as perdas nas exceções continuam maiores do que o previsto.
- **Testes múltiplos:** 8 rejeições em 88 nos setores (4,4 esperadas por acaso), nenhuma depois de Holm. Nas empresas, 105 em 872 (43,6 esperadas), nenhuma depois de Holm (FHS: 213 e 0).

D. Validação

- `gpd_quantile` é igual a `scipy.stats.genpareto.ppf` (erro relativo < 10^{-12}) e `gpd_es` à média numérica de 200 000 quantis da cauda.
- Com resíduos simulados de uma t(4), o ajuste recupera os quantis de 1% e 0,1% com erro inferior a 10%; com resíduos normais, $\hat{\xi}$ fica perto de zero.
- Na simulação do Z2, a fração de cenários na cauda é a prevista (10%).
- McNeil–Frey: com o ES certo não rejeita; com o ES 25% abaixo, $p < 1\%$; com o ES a mais não rejeita (teste unilateral).

E. Limitações

- O limiar de 10% é fixo, como no livro; não foi otimizado nem testada a sensibilidade a outros valores.
- $\hat{\xi}$ é limitado a 0,9, para o ES ser finito.
- A mudança de modelo cria uma quebra nas séries do score e dos alertas a 2026-11-12: nesse dia, o alerta "XLE: semáforo amarelo → verde" vem da troca de método, não do mercado.

---

16. Modelos de fatores: regressão conjunta e risco próprio das empresas (Fase C)

Código: `src/models/factor_links.py::fit_multivariate_ridge` e `src/models/decomposicao.py` · parâmetros: `FACTOR_RIDGE_ALPHA`, `FACTOR_BETA_MIN`, `DECOMP_MIN_DAYS` · testes: `tests/test_factor_links.py`, `tests/test_decomposicao.py`. Saídas: colunas novas em `factor_links.csv` (`beta_pad_multi`, `b_multi`, `t_multi`, `n_multi`, `aceite_multi`, `sinal_multi`) e `company_factors.csv`. Referência: QRM, secção 3.4.

A. Os seis fatores ao mesmo tempo

As 66 regressões da secção 9 usam um fator de cada vez. Como o VIX e os spreads sobem juntos, uma ligação pode ser só o reflexo de outro fator. A regressão conjunta mede o efeito de cada fator com os outros cinco fixos:

- **Dados:** só as semanas em que todos os fatores e setores têm valor (o FRED pode vir uma semana atrás do Yahoo).
- **Padronização:** cada fator e cada retorno com média 0 e desvio-padrão 1 na janela, para os coeficientes serem comparáveis entre unidades diferentes (p.p. e log-retornos).
- **Ridge:** $\hat{\beta}^{pad} = (Z^\top Z + \alpha I)^{-1} Z^\top y$, com α = `FACTOR_RIDGE_ALPHA` = 1. Na escala original, $b = \hat{\beta}^{pad}\, \sigma_y / \sigma_x$.
- **Aceitação:** $|\hat{\beta}^{pad}| \geq$ `FACTOR_BETA_MIN` = 0,05 **e** $|t| \geq$ `LINK_T_MIN` = 2, com o t HAC da regressão conjunta sem penalização. O sinal segue a convenção da secção 9.
- **Leitura honesta do Ridge:** com cerca de 155 semanas, $\alpha = 1$ quase não encolhe os coeficientes ($Z^\top Z$ tem diagonal 154). Quem separa os fatores correlacionados é a regressão ser conjunta; o limiar de 0,05 sozinho aceitaria quase tudo, por isso exige-se também o teste t.
- **Validação:** o coeficiente é igual ao de `sklearn.linear_model.Ridge` (erro relativo < 1e-9). Com dados simulados em que A causa o setor e B só anda com A ($r \approx 0{,}85$), a regressão de um fator aceita B por engano e a conjunta não.

Resultados (semanas 2023-11-17 → 2026-11-13): 28 ligações resistem. Das 34 aceites uma a uma, 12 deixam de o ser e aparecem 6 novas.

- **Somem:** a inflação implícita em XLK, XLF, XLE e XLI; os juros no XLE (t de +3,0 para +0,1: o efeito era do petróleo e da inflação); o VIX em XLV, XLP e XLRE; os spreads em XLE e XLV; o dólar em XLV e XLRE.
- **Aparecem:** os juros a agravar XLV, XLY e XLB; a inflação no XLY; o petróleo no XLI e no XLU. São efeitos que estavam escondidos por outros fatores.
- **O que não muda:** o Sentinela, o choque de juros e os cenários de stress continuam a usar o β de um fator de cada vez. Num choque de um só fator, esse β é o efeito total, incluindo o que costuma vir com ele; o conjunto responde a outra pergunta (o fator com tudo o resto parado).

B. De onde vem o risco de cada empresa

$$r_i = a + b_m\, r_{SPY} + b_s\, r^{\perp}_{setor} + e_i, \qquad r^{\perp}_{setor} = r_{setor} - \hat{\beta}_{setor,SPY}\, r_{SPY}$$

Como r_{SPY} e $r^{\perp}_{setor}$ não têm correlação na amostra, a variância separa-se sem termos cruzados:

$$1 = \underbrace{\frac{b_m^2 \operatorname{Var}(r_{SPY})}{\operatorname{Var}(r_i)}}_{\text{mercado}} + \underbrace{\frac{b_s^2 \operatorname{Var}(r_{setor}^{\perp})}{\operatorname{Var}(r_i)}}_{\text{setor}} + \underbrace{\frac{\operatorname{Var}(e_i)}{\operatorname{Var}(r_i)}}_{\text{próprio}}$$

- **Dados:** retornos simples diários, janela `CVAR_YEARS` = 3 anos, mínimo de 252 dias comuns.
- **Validação:** mercado + setor é igual ao R^2 de uma regressão do `statsmodels` em SPY e no ETF do setor, e a parte do mercado é igual à correlação com o SPY ao quadrado.
- **Resultados (110 empresas, dados até 2026-11-12):** mediana de 13% mercado, 21% setor e 56% próprio. Na energia e nas utilities o setor explica cerca de metade (XOM: 83% setor, 16% próprio). No outro extremo, MCD e VZ têm mais de 90% de risco próprio.
- **No cockpit:** coluna "Risco próprio" na tabela de empresas de cada setor e uma linha na ficha da empresa.

C. Limitações

- A ordem conta: o mercado entra primeiro e fica com tudo o que partilha com o setor. A parte "setor" é só o que o setor acrescenta ao mercado.
- A empresa faz parte do ETF do seu setor, o que aumenta a parte do setor nas empresas com mais peso (AAPL e NVDA no XLK).
- É uma decomposição da variância de todos os dias, não da cauda: não diz de onde vêm as perdas nos piores dias.
- A regressão conjunta usa 3 anos de semanas (cerca de 155 observações para 6 fatores); os coeficientes de fatores muito correlacionados continuam imprecisos.

🎲 17. Cenários conjuntos: se um setor tiver um dia mau (Fase D)

Código: `src/models/cauda.py` (`simulate_t_copula`, `scenarios`) · parâmetros: `CAUDA_Q`, `CAUDA_NSIM` · testes: `tests/test_cauda.py`. Saída: `data/features/tail_scenarios.csv` (um par ordenado cenário → setor por linha). Referência: QRM, secção 5.1 e algoritmo 5.10.

A. Método

1. **Simulação:** 200 000 dias de uma cópula t assimétrica (skewed t; McNeil, Frey e Embrechts, 2005), $X = \gamma W + \sqrt{W}\, Z$, com $Z \sim N(0, \rho)$ e $W = \nu/\chi^2_\nu$. ρ (pelo tau de Kendall) e ν (máxima verosimilhança) são ajustados aos **retornos** de 3 anos, com os seus períodos agitados; as margens de X não têm fórmula simples, por isso os uniformes são as ordens de cada coluna na própria simulação. Com $\gamma = 0$ é a cópula t.
2. **Margens:** cada uniforme passa a retorno pelo quantil observado do setor na janela de 3 anos (margens empíricas).
3. **Cenário:** para cada setor A, ficam os dias simulados em que A está nos seus 5% piores (cerca de 10 000). Em cada outro setor B mede-se:
   - `p_cauda`: a fração desses dias em que B também está nos seus 5% piores;
   - `perda_media`: a perda média de B nesses dias.

4. **Assimetria (desde 2026-11-14):** $\gamma < 0$ dá mais quedas conjuntas do que subidas conjuntas. Escolhe-se γ numa grelha de 0 a −0,6 para a simulação acertar ao mesmo tempo as duas médias observadas: quedas conjuntas 27,9% e subidas conjuntas 24,2% (método dos momentos, um parâmetro para dois momentos). Resultado: $\gamma = -0{,}15$, $\nu = 7{,}6$.
5. **Confronto:** as colunas `p_obs` e `perda_obs` são as mesmas medidas contadas nos dias reais da janela (cerca de 38 por cenário).

B. Validação

- As margens simuladas são uniformes e o tau de Kendall devolve o ρ pedido.
- Com ν muito alto, `p_cauda` é igual à probabilidade da normal bivariada do `scipy` (diferença < 0,01).
- Com $\nu = 3$ há mais quedas conjuntas do que com Gauss, e a 1% o valor simulado fica acima do limite λ da secção 14.
- Com $\gamma = 0$ as quedas e as subidas conjuntas simuladas são iguais; com $\gamma = -0{,}4$ há pelo menos 5 pontos mais de quedas; dados gerados com $\gamma = -0{,}3$ devolvem um γ entre −0,45 e −0,15.

C. Resultados (dados até 2026-11-13)

Cenário: dia mau do XLK (perda média 3,8%)	Cai junto, observado	Cai junto, simulado	Perda média, observada	Perda média, simulada
XLI	46%	37%	1,6%	1,3%
XLY	41%	38%	1,9%	1,7%
XLC	41%	31%	1,5%	1,2%

Na média dos 110 pares ordenados, a probabilidade de cair junto simulada é **26,8%** contra 27,9% observados, e a perda média do outro setor 0,93% contra 1,03%.

Antes desta versão (cópula t simétrica ajustada aos resíduos do GARCH) a simulação dava 22,9% e 0,80%. Duas razões: a cópula era simétrica, quando nos mercados as quedas andam mais juntas do que as subidas (27,9% contra 24,2%), e os resíduos do GARCH não têm os períodos de volatilidade alta comuns a todos os setores. Passar aos retornos sobe a média para 23,9%; a assimetria leva-a a 26,8%. Uma mistura de duas cópulas t (dias calmos e agitados) também foi testada: chega a cerca de 25%, mas continua simétrica.

O cockpit continua a mostrar primeiro o observado e depois a simulação, e não usa a simulação para alertas nem para o score.

D. Limitações

- O observado assenta em cerca de 38 dias por cenário (erro-padrão de uns 7 pontos percentuais em cada probabilidade).
- A simulação ainda fica cerca de 1 ponto abaixo do observado na média, e mais nalguns pares (XLK–XLC: 31% contra 41%); com um só γ para todos os setores, a assimetria é igual em todos os pares. (Antes: t assimétrica ou Clayton) seria o passo seguinte.

- Os cenários são de um dia e sem a volatilidade de hoje: dizem o que acontece num dia mau típico da janela, não num dia mau de amanhã.

📅 18. Horizontes de 10 dias e de 1 mês (Fase E)

Código: `src/models/horizonte.py` · parâmetros: `HORIZONS`, `HORIZON_NSIM`, `HORIZON_BT_NSIM` · testes: `tests/test_horizonte.py`. Saídas: `data/features/horizon_risk.csv` (previsão de hoje) e `horizon_backtest.csv`. Referência: QRM, secção 2.3.4; McNeil e Frey (2000).

A. Método

A regra da raiz do tempo, $\mathrm{VaR}_h = \sqrt{h}\,\mathrm{VaR}_1$, só vale para retornos independentes com a mesma distribuição. Com GARCH, a volatilidade de hoje regressa à média ao longo do horizonte. Por isso simula-se dia a dia, a partir do GJR-GARCH do modelo oficial:

$$r_d = \mu + \sigma_d z_d, \qquad \sigma^2_{d+1} = \omega + (\alpha + \gamma\,1[\varepsilon_d < 0])\,\varepsilon^2_d + \beta\,\sigma^2_d, \qquad \varepsilon_d = \sigma_d z_d$$

- **Resíduos z_d:** sorteados como no modelo oficial (EVT: reamostragem no corpo, Pareto na cauda).
- **Perda a h dias:** $L_h = -\left(e^{\sum_d r_d} - 1\right)$, em retorno simples. O VaR e o ES são o quantil e a média da cauda de 20 000 trajetórias.
- **Horizontes:** 10 dias úteis (o horizonte regulamentar de Basileia) e 21 (um mês).

B. Validação

- A recursão da variância é igual a um cálculo à mão com o resíduo fixo.
- Com volatilidade constante e resíduos normais, o VaR a 10 dias é $\sqrt{10}$ vezes o de 1 dia (erro < 3%).
- A 1 dia, o VaR e o ES simulados batem com os do modelo oficial, calculados por fórmula fechada (erro < 4%).
- Com a volatilidade de hoje a 3 vezes a de longo prazo, o VaR a 10 dias fica abaixo de 90% da raiz do tempo.

C. Backtest (blocos sem sobreposição, 2008–2026)

Em cada bloco de h dias, o VaR previsto na véspera é comparado com a perda do bloco. Exceções somadas nos 11 setores:

Horizonte	Nível	Blocos	Esperadas	Simulação	Raiz do tempo
10 dias	97,5%	4 604	115	121	122
10 dias	99%	4 604	46	50	48
21 dias	97,5%	2 185	55	43	40
21 dias	99%	2 185	22	20	24

- **A simulação não é rejeitada:** o teste de Kupiec passa nos 11 setores a 10 dias e em 10 ou 11 a 21 dias.

- **Leitura honesta:** na frequência de exceções, a simulação e a raiz do tempo ficam quase iguais. A diferença está no dia a dia: quando a volatilidade está alta, a simulação prevê menos do que a raiz do tempo, e quando está baixa prevê mais.
- **Previsão de 2026-11-13 (ES 97,5%):** XLK 8,2% a 1 dia, 24,9% a 10 dias (raiz do tempo: 25,9%) e 33,4% a 21 dias (37,5%). No XLE, 10,9% a 10 dias contra 13,3% pela raiz do tempo.

D. Limitações

- Com cerca de 420 blocos de 10 dias por setor, esperam-se 10 exceções a 97,5% e 4 a 99%: o teste tem pouca força para distinguir os dois métodos.
- Só a frequência de exceções é testada; o ES a 10 e 21 dias não tem backtest.
- Os parâmetros do GARCH ficam fixos durante o horizonte, e a média diária μ estimada em 3 anos é somada todos os dias.
- Os horizontes existem para os 11 setores e, desde a Fase 6, para a carteira do utilizador (o mesmo `horizonte.forecast` sobre os retornos com os pesos atuais; ex.: ES 97,5% de 13,6% a 10 dias e 17,4% a 1 mês na carteira do exemplo, contra 14,4% e 20,8% pela raiz do tempo). As empresas continuam a 1 dia.

---

19. Teia de risco e motor de cenários (Fases 2 e 3)

Código: `app/cockpit/paineis/teia.py` (teia em ECharts), `src/models/cenarios.py` (motor) e `app/cockpit/paineis/cenario.py` (painel) · parâmetros: `CENARIO_*` · testes: `tests/test_teia.py`, `tests/test_cenarios.py`. Saídas: `data/features/cenario_semanal.parquet` (os dados semanais que o cockpit usa para simular ao vivo) e `cenario_validacao.csv`.

A. A teia

O Mapa de risco passou a ter uma vista única em anéis: os seis fatores macro no centro, os 11 setores no anel do meio e as 10 maiores empresas de cada setor no anel de fora.

- **Ligações dos fatores:** só as que resistem na regressão conjunta (secção 16). Vermelho cheio quer dizer que o fator a subir agrava o setor; verde tracejado que atenua (o tracejado distingue-as sem depender da cor).
- **Ligações entre setores:** a árvore das quedas conjuntas da janela escolhida (secção 14.G). Os setores que caem juntos ficam vizinhos no anel.
- **Cliques:** um fator mostra a sua cadeia, com partículas a correr do fator para os setores e, com um atraso, para as empresas; um setor abre as empresas num leque, ligadas entre si pelas que caem juntas; uma empresa abre a ficha.
- **Biblioteca:** ECharts, pelo componente `streamlit-echarts`, escolhido depois de um protótipo com os dados reais. O mapa anterior, em Plotly, continua disponível num interruptor.
- **Um só separador (Fase 4):** a teia passou a ser o separador "Teia de risco". Os antigos separadores Setores (scorecard) e Fatores macro aparecem por baixo da teia quando nenhum setor está aberto, e o mapa anterior em Plotly foi apagado. As posições da Minha carteira têm

contorno branco, e o simulador de choques dá o resultado da carteira: $\sum_i w_i r_i$ em cada cenário, nas posições que o modelo cobre (o SPY é o fator mercado), com os pesos re-normalizados.

B. O motor de cenários

Responde a "se este fator se mexer assim, o que acontece aos setores e às empresas?". Usa dados semanais dos últimos 10 anos (`CENARIO_ANOS`), com sete fatores: os seis macro e o mercado (retorno log do SPY), porque é pelo mercado que as crises chegam aos setores. Em cada um de 5 000 cenários de h semanas:

1. **Fatores:** os escolhidos ficam com a variação pedida; os outros seguem a normal condicional, com a média e a covariância semanais da janela, escaladas por h:

$$\mathbb{E}[x_u \mid x_s] = h\mu_u + \Sigma_{us}\Sigma_{ss}^{-1}(x_s - h\mu_s), \qquad \mathrm{Cov}[x_u \mid x_s] = h\left(\Sigma_{uu} - \Sigma_{us}\Sigma_{ss}^{-1}\Sigma_{su}\right)$$

2. **Setores:** $r_s = h\,a_s + B_s x + k\sum_{j=1}^{h}\varepsilon_{s,t_j}$. B vem da regressão de cada setor nos sete fatores ao mesmo tempo (OLS); os resíduos são semanas inteiras sorteadas do passado, o que guarda as caudas e a dependência entre setores.
3. **Empresas:** $r_i = h\,\alpha_i + \beta_i r_s + \sum_k e_{i,t_k}$, com β_i da regressão semanal na do seu ETF e os resíduos sorteados nas mesmas semanas que os dos setores.

Alargamento nas crises (desde 2026-11-14): nas semanas agitadas os setores afastam-se mais do que os fatores explicam. Estima-se, na janela, a dispersão dos resíduos de cada semana em função da intensidade do movimento dos fatores (distância de Mahalanobis à média), $s(I) = a + bI$, e os resíduos do cenário são multiplicados por $k = \max\{1,\ s(I^*)/s(\tilde{I})\}$, em que I^* é a intensidade do choque por semana e $\tilde{I}$ a de uma semana típica. Num choque normal $k = 1$; na COVID-19, $k \approx 1{,}5$. Sortear só as semanas mais parecidas com o choque, ou estimar B só nelas, foi testado e não melhorou.

Incerteza dos parâmetros (desde 2026-11-14): os 5 000 cenários repartem-se por 50 conjuntos de parâmetros (`CENARIO_NBOOT`): o estimado na amostra e 49 estimados em semanas reamostradas com reposição. Assim, os intervalos incluem também a incerteza de B, de β_i e da covariância dos fatores.

Intervalos do modelo, não de confiança: os quantis de 5% e 95% são os do modelo, dados os seus pressupostos. A cobertura real medida nas crises (secção C) é mostrada no cockpit ao lado dos resultados.

Os retornos log somados passam a simples ($e^r - 1$). O painel mostra a mediana, os 5% piores e melhores e a probabilidade de perder, e a teia passa a ter a cor da mediana (vermelho perde, verde ganha). Os setores e as empresas da cadeia do fator chocado mostram a sua percentagem; cada ligação desse fator a um setor mostra o efeito direto, $e^{B_{s,f}\,x_f} - 1$, que é só o canal desse fator. A diferença para o número do setor é o que chega pelos outros fatores, sobretudo pelo mercado. Estimar e simular demora cerca de 0,05 s, por isso corre ao vivo.

Validação: o coeficiente B é recuperado em dados simulados; a média condicional bate com a fórmula; sem choque, a dispersão simulada dos fatores é a da janela; o teste dos episódios não usa nenhuma semana depois do início da crise.

C. Teste em três crises, fora da amostra

Para cada crise, o modelo é estimado só com as semanas anteriores e recebe as variações reais dos fatores durante a crise. Compara-se a previsão de cada setor com o que aconteceu. Há duas versões: só os seis fatores macro (o mercado fica condicional, como num cenário normal) e os macro mais o mercado real.

Crise (semanas)	Fatores impostos	Setores dentro do intervalo de 90%	Correlação previsto × real	Erro médio	Desvio médio
Lehman, 2008 (10)	só macro	2 de 9	0,23	21,2 p.p.	+17,7 p.p.
	macro + mercado	5 de 9	0,50	10,8 p.p.	+0,5 p.p.
COVID-19, 2020 (4)	só macro	1 de 11	0,79	16,8 p.p.	+16,8 p.p.
	macro + mercado	6 de 11	0,73	5,0 p.p.	+3,5 p.p.
Juros, 2022 (24)	só macro	4 de 11	0,20	17,8 p.p.	+10,4 p.p.
	macro + mercado	5 de 11	0,38	12,8 p.p.	–7,7 p.p.

Desvio positivo = o modelo previu perdas menores do que as reais.

- **Só com os fatores macro, o modelo subestima as crises:** a perda prevista ficou em média 15 pontos abaixo da real. A relação entre os fatores e o mercado estimada em tempos calmos é linear e não capta o pânico.
- **Com o mercado real, a mediana acerta bem** em 2008 e 2020 (desvio de 0,5 e 3,6 pontos). Em 2022 os setores dividiram-se mais do que o modelo prevê (energia +34%, comunicações –31%).
- **Os intervalos continuam estreitos:** num intervalo de 90% deviam cair cerca de 28 dos 31 setores-crise. Com o mercado conhecido caem 16 (52%; 13 antes da incerteza dos parâmetros e 10 antes do alargamento nas crises); só com os fatores macro, 7 (23%), porque aí o que falha é a mediana, não a largura. Por isso o cockpit chama-lhes intervalos do modelo e mostra esta cobertura ao lado.
- **Leitura:** o motor serve para ver para onde um choque empurra cada setor e quais sofrem mais do que outros. Não serve para dar a dimensão exata de uma crise; o painel diz isto ao lado dos resultados.

D. Limitações

- A normal condicional e as regressões são lineares; nas crises as relações mudam.
- Os parâmetros ficam fixos no horizonte, e o horizonte é uma soma de semanas independentes (raiz do tempo nos fatores).
- As empresas só se ligam ao seu setor; não há ligação direta de uma empresa a um fator.
- Quando um setor ou uma empresa ainda não existia, os resíduos dessas semanas são sorteados da própria série.

Referências

- López de Prado, M. (2016). *Building Diversified Portfolios that Outperform Out of Sample*. Journal of Portfolio Management, 42(4).
- Acerbi, C. e Székely, B. (2014). *Backtesting Expected Shortfall*. Risk, dezembro de 2014.
- Barone-Adesi, G., Giannopoulos, K. e Vosper, L. (1999). VaR without correlations for portfolios of derivative securities. *Journal of Futures Markets*, 19(5), 583–602.
- Basel Committee on Banking Supervision (1996). *Supervisory framework for the use of "backtesting" in conjunction with the internal models approach to market risk capital requirements*.
- Basel Committee on Banking Supervision (2019). *Minimum capital requirements for market risk* (FRTB, d457).
- Christoffersen, P. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- Glosten, L., Jagannathan, R. e Runkle, D. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- Kupiec, P. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- Ledoit, O. e Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- McNeil, A. e Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: an extreme value approach. *Journal of Empirical Finance*, 7(3–4), 271–300.
- McNeil, A., Frey, R. e Embrechts, P. (2005). *Quantitative Risk Management: Concepts, Techniques and Tools*. Princeton University Press.
- Mantegna, R. (1999). Hierarchical structure in financial markets. *European Physical Journal B*, 11, 193–197.
- Newey, W. e West, K. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3), 703–708.
- Newey, W. e West, K. (1994). Automatic lag selection in covariance matrix estimation. *Review of Economic Studies*, 61(4), 631–653.
- Rockafellar, R. T. e Uryasev, S. (2002). Conditional value-at-risk for general loss distributions. *Journal of Banking & Finance*, 26(7), 1443–1471.
- Tasche, D. (2000). *Risk contributions and performance measurement*. Working paper, TU München.